

Московский авиационный институт
(национальный исследовательский университет)

Факультет информационных технологий и прикладной
математики

Кафедра вычислительной математики и программирования

Отчет по сделанной работе в рамках курса
«Информационный поиск»

Студент: Т. А. Бучкин
Преподаватель: А.А. Кухтичев
Группа: М8О-401Б
Дата: 24.12.2025
Оценка:
Подпись:

Москва, 2025

Постановка задачи

Задача: Необходимо описать систему реализующую интерфейс текстового поиска: булевого и цитатного

1 Описание

В качестве корпуса документов я выбрал новостные сайты. Список сайтов представлен ниже:

- <https://ria.ru/>
- <https://www.kp.ru/>
- <https://lenta.ru/>
- <https://iz.ru/>
- <https://russian.rt.com/>
- <https://tass.ru/>
- <https://www.interfax.ru/>
- <https://www.gazeta.ru/>
- <https://www.rbc.ru/>
- <https://www.mk.ru/>
- <https://rg.ru/>
- <https://www.kommersant.ru/>
- <https://aif.ru/>
- <http://sports.ru/>
- <https://ura.news/>
- <https://www.vedomosti.ru/>
- <https://regnum.ru/>
- <https://mediakit.iportal.ru/>
- <https://tsargrad.tv/>
- <https://riafan.ru/>

По предварительным расчетам, сайты в среднем выпускают по 5 новостей за день, за год получается примерно 2000 с сайта. Средний период новостей, которые хранит сайт – 10 лет, так что с одного сайта можно выкачать 20000 документов. Сайтов в списке 20, так что при полной обкатке сайтов получится корпус из 400000 документов.

2 Архитектурное решение

Я решил разделить проект на отдельные компоненты, которые реализуют следующие функции, необходимые для поиска:

1. Обкачка интернета
2. Индексация страниц
3. Токенизация текста
4. Хранение индекса(прямого и обратного)
5. Поиск по индексу
6. Обработка поисковых запросов

Для этого я выделил следующие компоненты:

1. База данных
Хранение индекса и поиск по нему
2. Токенизатор
Разбиение текста на токены и сборка из токенов текста
3. Индексатор
Индексация страниц, т.е. их токенизация и сохранение в БД
4. Поисковик
Поиск страниц, подходящий под поисковый запрос
5. Хранение сырых документов документов
6. Обкатчик новостных сайтов

Для деплоя проекта я решил использовать технологию docker, т.к. это удобно.

1 Общий подход к организации сервисов

3 Выводы

Выполнив первую лабораторную работу по курсу «Информационный поиск», я научился подбирать корпус документов для дальнейшей обработки в процессе выполнения следующих лабораторных работ.

Размер "сырых" данных	Ограничение задается
Количество документов	Ограничение задается
Размер теста, выделенного из "сырых" данных	Полная html-страница, возможно, будут удалены
Средний размер документа	30 кБайт